[AI2613 第一次作业]

- 最近更新时间: 18:07, Mar 10, 2026
- 关于**AI使用**的说明：本次作业允许讨论和参考课外资料。如果在完成作业的过程中，与他人进行了讨论或参考了其他资料（包括使用AI工具），请在具体题目旁明确标注：和哪位同学探讨了思路，或参考了什么资料，或使用了哪种AI工具及其具体用途与使用程度。允许使用AI查询概念、LaTeX语法和检索公开资料；禁止使用AI直接生成答案、推导核心步骤或改写他人作业。
- 关于**附加题**的说明：作业中的附加题是选做的，会由助教进行批改，以供学习和反馈。但是这些题目的成绩不会纳入最终的作业总分，也不会提供额外的分数奖励。

问题1（再探奖券收集）

在课堂上中，我们用切比雪夫不等式分析了奖券收集问题，得到了 $\mathbb{P}\left[Y \geq nH_n + t\right] \leq \frac{2n^2}{t^2}$，其中 n 是奖券类型总数， Y 是收集齐全 n 种奖券所需的抽奖次数。现在我们用另一种方法来计算这个问题的集中性。

请用 Union Bound 分析存在一种奖券类型在前 $nH_n + t$ 次抽奖中都没有被抽到的概率。并据此证明

$$\mathbb{P}\left[Y \geq nH_n + t\right] \leq e^{-t/n}.$$

问题1解答

令 Y_i表示第 i 种奖券被抽到所需的次数，则$\{Y \geq nH_n + t\} = \cup\{Y_i \geq nH_n + t\}$,
$\mathbb{P}\left[Y \geq nH_n + t\right] = \mathbb{P}\left[\cup\{Y_i \geq nH_n + t\}\right] \leq \sum \mathbb{P}\left[Y_i \geq nH_n + t\right]$.
Y_i服从几何分布，$\mathbb{P}\left[Y_i \geq nH_n + t\right] = (1 - \frac{1}{n})^{nH_n + t} \leq e^{-H_n - t/n} \leq \frac{1}{n} e^{-t/n}$,
其中第二个不等号是因为$H_n \geq \ln n$.
故$\mathbb{P}\left[Y \geq nH_n + t\right] \leq e^{-t/n} \square$

问题2（均匀性测试）

在公平硬币检验中，我们讲了如何区分公平硬币和有偏硬币。现在我们来推广这个问题。

考虑概率空间 $\Omega = \{1, 2, \ldots, n\}$。对于 Ω 上的任意一个分布 q，令 q_i 表示从分布 q 中采样一次得到样本为 i 的概率（$i \in [n]$）。对于 Ω 上的两个分布 p 和 q，定义其总变分距离(total variation distance)为 $\mathtt{TV}(p, q) = \frac{1}{2} \sum_{i=1}^{n} |p_i - q_i|$。

令 μ 是 Ω 上的均匀分布，π 是 Ω 上的一个未知分布。假设我们已经知道 π 要么就是均匀分布（即 $\pi = \mu$），要么与均匀分布差别很大，即 $\mathtt{TV}(\pi, \mu) \geq \varepsilon$（其中 $\varepsilon \in (0, 1/2)$ 是一个已知的常数）。均

匀性测试问题指的是，通过从分布中采样，来判断它到底是均匀分布还是距离均匀分布很远。在这个问题里，我们来设计一个高效的均匀性测试算法，即使用尽量少的样本来保证至少 $1-\delta$ 的判断准确概率。

大家可以首先猜一下我们至少需要多少个样本才能达到这个目标。我们在课上讲了奖券收集问题，知道平均需要大约 $n\log n$ 个样本，才能够保证每一个样本都被采集到。这是否说明，判断目标分布是不是均匀分布，至少需要 $\Omega(n\log n)$ 个样本呢?

实际上，我们可以用少得多的样本达到这个目标。我们一起来设计一个算法，只要用 $O(\sqrt{n})$ 的样本就可以了。假设 $n=10000$，那么我们只要取几百个样本就能判断是不是均匀分布，我们并不需要获得绝大多数样本的信息。我们用到的工具就是课上提到的生日悖论，我们知道如果 π 是均匀分布，那么实际上大约 $\Theta(\sqrt{n})$ 个样本就可以保证高概率出现两个同样的样本。我们接下来的讨论将说明，均匀分布是让这件事最难发生的分布，并利用这个事实来判断一个分布是不是均匀分布。

1. 令 $\|\pi\|=\sqrt{\sum_{i=1}^n \pi_i^2}$。假设 X 和 Y 是独立地从 π 中采的两个样本，请证明 $\mathbb{P}\left[X=Y\right]=\|\pi\|^2$。这里 $\|\pi\|^2$ 被称为碰撞概率。
   证明: $\mathbb{P}\left[X=Y\right]=\sum_{i=1}^n \mathbb{P}\left[X=i\right]\mathbb{P}\left[Y=i\right]=\sum_{i=1}^n \pi_i^2=\|\pi\|^2.$

2. 请证明:

   i. $\|\mu\|^2=\frac{1}{n}$;

   ii. 若 $\mathtt{TV}(\pi,\mu)\geq\varepsilon$，则有 $\|\pi\|^2-\|\mu\|^2\geq\frac{4\varepsilon^2}{n}$。
   证明: 1. $\|\mu\|^2=\sum_i \mu_i^2=\sum_{i=1}^n(\frac{1}{n})^2=\frac{1}{n}.$
   2. $\mathtt{TV}(\pi,\mu)=\frac{1}{2}\sum_i|\pi_i-\mu_i|\geq\varepsilon$ ， 令 $z_i=\pi_i-\mu_i$ ， 则 $\sum_i|z_i|\geq 2\varepsilon$ 且 $\sum_i z_i=0.$
   $\sum_i\|\pi_i\|^2-\|\mu_i\|^2=\sum_i z_i^2+2z_i=\sum_i z_i^2\geq_{Cauchy}\frac{1}{n}(\sum_i|z_i|)^2\geq\frac{4\varepsilon^2}{n}$

3. 假设 $X_1,X_2,\ldots,X_m$ 是 m 个从 π 中独立采出的样本点（$m\geq 4$），对于 $1\leq i<j\leq m$，定义随机变量 $Y_{ij}=\mathbb{I}\{X_i=X_j\}$。令 $Z=\frac{1}{\binom{m}{2}}\sum_{1\leq i<j\leq m}Y_{ij}$ 表示碰撞发生的频率，请证明:

   i. $\mathbf{E}\left[Z\right]=\|\pi\|^2$;

   ii. $\mathbf{Var}\left[Z\right]\leq\frac{4\|\pi\|^3}{m}+\frac{4\|\pi\|^2}{m^2}$;
   ▶ 提示

   iii. 无论 $\pi=\mu$ 或 $\mathtt{TV}(\pi,\mu)\geq\varepsilon$，都有

$$\mathbb{P}\left[|Z-\mathbf{E}\left[Z\right]|\geq\varepsilon^2\mathbf{E}\left[Z\right]\right]\leq\frac{4\sqrt{n}}{\varepsilon^4 m}+\frac{4n}{\varepsilon^4 m^2}.$$

证明: 1. $\mathbf{E}\left[Z\right]=\frac{1}{\binom{m}{2}}\sum_{i<j}\mathbf{E}\left[Y_{ij}\right]=\frac{1}{\binom{m}{2}}\sum_{i<j}\mathbb{P}\left[X_i=X_j\right]$
$=\frac{1}{\binom{m}{2}}\sum_{i<j}\sum_k\mathbb{P}\left[X_i=k\right]\mathbb{P}\left[X_j=k\right]=\sum_k\pi_k^2=\|\pi\|^2.$
2. $\mathbf{Var}\left[Z\right]=\frac{1}{\binom{m}{2}^2}\sum_{i<j}\mathbf{Var}\left[Y_{ij}\right]+\frac{1}{\binom{m}{2}^2}\sum_{i<j,k<l,(i,j)\neq(k,l)}\mathrm{Cov}\left(Y_{ij},Y_{kl}\right)$
$=\frac{1}{\binom{m}{2}^2}\sum_{i<j}\mathbf{E}\left[Y_{ij}^2\right]-\mathbf{E}[Y_{ij}]^2+\frac{1}{\binom{m}{2}^2}\sum_{i<j,k<l,(i,j)\neq(k,l)}\mathbf{E}\left[Y_{ij}Y_{kl}\right]-\mathbf{E}\left[Y_{ij}\right]\mathbf{E}\left[Y_{kl}\right]$

$= \frac{1}{\binom{m}{2}} \sum_k (\pi_k^2 - \pi_k^4) + \frac{1}{\binom{m}{2}^2} \sum_{i<j,k<l,\#|(i,j)\cup(k,l)|=3} \mathbf{E}\left[Y_{ij}Y_{kl}\right] - \mathbf{E}\left[Y_{ij}\right]\mathbf{E}\left[Y_{kl}\right]$
$= \frac{1}{\binom{m}{2}} \sum_k (\pi_k^2 - \pi_k^4) + \frac{m}{\binom{m}{2}} \sum_k (\pi_k^3 - \pi_k^4)$
这里用到了$Y_{ij}^2 = Y_{ij}$，和当指标(i,j)和(k,l)没有公共元素时，Y_{ij}和Y_{kl}独立。
放缩掉负项并利用提示的不等式以及$m \geq 4$可得$\mathbf{Var}\left[Z\right] \leq \frac{4\|\pi\|^3}{m} + \frac{4\|\pi\|^2}{m^2}\square$
3. 考虑Chebyshev不等式：$\mathbb{P}\left[|Z - \mathbf{E}\left[Z\right]| \geq \varepsilon^2 \mathbf{E}\left[Z\right]\right] \leq \frac{\mathbf{Var}[Z]}{\varepsilon^4 \mathbf{E}[Z]^2}$.
$\frac{\mathbf{Var}[Z]}{\varepsilon^4 \mathbf{E}[Z]^2} \leq (\frac{4\|\pi\|^3}{m} + \frac{4\|\pi\|^2}{m^2}) \cdot \frac{1}{\varepsilon^4 \|\pi\|^4} = \frac{4}{\varepsilon^4 m \|\pi\|} + \frac{4}{\varepsilon^4 m^2 \|\pi\|^2} \leq \frac{4}{\varepsilon^4 m \|\mu\|} + \frac{4}{\varepsilon^4 m^2 \|\mu\|^2} = \frac{4\sqrt{n}}{\varepsilon^4 m} + \frac{4n}{\varepsilon^4 m^2}$

这里用到了2.请证明中的$\|\mu\|^2 = \frac{1}{n}$和$\|\pi\| \geq \|\mu\|$.

4. 根据以上结论，我们知道当 $\mathtt{TV}(\pi, \mu) \geq \varepsilon$ 时碰撞发生概率明显大于均匀分布下碰撞发生概率，于是我们可以考虑根据碰撞发生频率 Z 的大小来判断 π 是否为均匀分布。我们考虑如下算法：

- 从 π 中独立地采 $m = \frac{100\sqrt{n}}{\varepsilon^4}$ 个样本点，并计算 Z 的值；
- 若 $Z \geq \frac{1+2\varepsilon^2}{n}$，则输出 $\mathtt{TV}(\pi, \mu) \geq \varepsilon$，反之输出 $\pi = \mu$。

请证明该算法出错概率不超过 0.1。
证明： 假设是均匀分布，则$\mathbf{E}\left[Z\right] = \|\mu\|^2 = \frac{1}{n}$，
$\mathbb{P}\left[Z \geq \frac{1+2\varepsilon^2}{n}\right] = \mathbb{P}\left[Z - \mathbf{E}\left[Z\right] \geq \frac{2\varepsilon^2}{n}\right] \leq \mathbb{P}\left[|Z - \mathbf{E}\left[Z\right]| \geq \frac{2\varepsilon^2}{n}\right]$,
$\leq \frac{\sqrt{n}}{\varepsilon^4 m} + \frac{n}{\varepsilon^4 m^2} = \frac{\sqrt{n}}{\varepsilon^4 \cdot \frac{100\sqrt{n}}{\varepsilon^4}} + \frac{n}{\varepsilon^4 \cdot (\frac{100\sqrt{n}}{\varepsilon^4})^2} = 0.01 + 0.0001 < 0.02.$
假设是非均匀分布，则$\mathbf{E}\left[Z\right] = \|\pi\|^2 \geq \|\mu\|^2 + \frac{4\varepsilon^2}{n} = \frac{1+4\varepsilon^2}{n}$,
$\mathbb{P}\left[Z \leq \frac{1+2\varepsilon^2}{n}\right] = \mathbb{P}\left[Z - \mathbf{E}\left[Z\right] \leq -\frac{2\varepsilon^2}{n}\right] \leq \mathbb{P}\left[|Z - \mathbf{E}\left[Z\right]| \geq \frac{2\varepsilon^2}{n}\right] \leq \mathbb{P}\left[|Z - \mathbf{E}\left[Z\right]| \geq \varepsilon^2 \mathbf{E}\left[Z\right.\right.$

$\leq \frac{4\sqrt{n}}{\varepsilon^4 m} + \frac{4n}{\varepsilon^4 m^2} = 0.04 + 0.0004 < 0.05.$
这里用到了$\varepsilon \in (0, \frac{1}{2}), \varepsilon^2 \leq \frac{1}{4}$. 综上，出错率不超过0.1。

问题3（区分的代价）

在公平硬币检验中，我们讲过如何用 $T = O\left(\frac{1}{\varepsilon^2} \log \frac{1}{\delta}\right)$ 个样本来判断一个硬币是公平的（$\mathrm{Ber}(1/2)$）还是有偏的（$\mathrm{Ber}(1/2+\varepsilon)$），且判断准确的概率至少为 $1-\delta$。在本题中，我们将证明（在忽略常数倍的意义下）这一算法是最优的。换言之，我们将证明任何满足该条件的算法在输入是公平硬币时必有 $\mathbf{E}\left[T\right] = \Omega\left(\frac{1}{\varepsilon^2} \log \frac{1}{\delta}\right)$。

设 $L = \frac{1}{100\varepsilon^2} \log \frac{1}{4\delta}$。假设 $\varepsilon \in (0, 1/8), \delta \in (0, e^{-4}/4)$。我们先考虑确定性算法，即随机性的唯一来源是扔硬币的结果。令 $\mathbb{P}_i\left[\cdot\right]$ 和 $\mathbf{E}_i\left[\cdot\right]$ 表示输入硬币是情况 i 时的概率和期望，其中 $i=0$ 表示是公平硬币，$i=1$ 表示是有偏硬币。使用反证法，假设存在一个满足要求的确定性算法 $\mathcal{A}$，满足 $\mathbf{E}_0\left[T\right] \leq L$。
考虑概率空间 $H_0 = (\Omega, \mathcal{F}, \mathbb{P}_0)$ 和 $H_1 = (\Omega, \mathcal{F}, \mathbb{P}_1)$，其中样本空间 $\Omega = \{0,1\}^*$。
定义如下三个事件：

- A: $T \leq 4L$;
- B: 对于任意 $1 \leq t \leq 4L$，$\left|K_t - \frac{t}{2}\right| \leq \sqrt{L \log \frac{1}{4\delta}}$，其中 K_t 表示前 t 次实验中正面的个数;
- C: $\mathcal{A}$ 输出 0，即认为硬币是公平的。

1. 下面这个定理是切比雪夫不等式的推广，请用这个定理证明 $\mathbb{P}_0[A \cap B \cap C] \geq 1/4$（此定理本身无需证明，可以直接使用）。

> 定理： 假设 $X_1, \ldots, X_N$ 是 N 个定义在同一个概率空间上的独立伯努利随机变量，令 $S_k = \sum_{i=1}^{k}(X_i - \mathbf{E}[X_i])$，那么对于任意的 $s > 0$,
>
> $$\mathbb{P}\left[\max_{1 \leq k \leq N} |S_k| \geq s\right] \leq \frac{\mathbf{Var}[S_n]}{s^2}.$$

证明: $\mathbb{P}_0[A \cap B \cap C] = 1 - \mathbb{P}_0\left[\overline{A} \cup \overline{B} \cup \overline{C}\right] \geq 1 - \mathbb{P}_0\left[\overline{A}\right] - \mathbb{P}_0\left[\overline{B}\right] - \mathbb{P}_0\left[\overline{C}\right]$.
关于事件B的定义问题：为了保证A交B有意义，我们规定当样本点长度不足4L时，将观测补足到4L，但这不影响T。
$\mathbb{P}_0\left[\overline{A}\right] = \mathbb{P}_0[T > 4L] \leq \frac{\mathbf{E}_0[T]}{4L} \leq \frac{1}{4}$.考虑Markov不等式。
$\mathbb{P}_0\left[\overline{B}\right] = \mathbb{P}_0\left[\max_{1 \leq t \leq 4L}\left|K_t - \frac{t}{2}\right| > \sqrt{L \log \frac{1}{4\delta}}\right]$.
用互相独立的随机变量 $X_i \sim \mathrm{Ber}(1/2)$ 表示第 i 次实验的结果，则 $K_t = \sum_{i=1}^{t} X_i$，$K_k - \frac{k}{2} = \sum_{i=1}^{k}(X_i - \frac{1}{2}) = \sum_{i=1}^{k}(X_i - \mathbf{E}[X_i])$.这里用到的是$\mathbb{P}_0[\cdot]$的先验。
$\mathbb{P}_0\left[\overline{B}\right] \leq_{\text{定理}} \frac{\mathbf{Var}[S_{4L}]}{L \log \frac{1}{4\delta}} = \frac{1}{\log \frac{1}{4\delta}} <_{\delta:Range} \frac{1}{4}$.
$\mathbb{P}_0\left[\overline{C}\right] = \mathbb{P}_0[\mathcal{A} \text{ outs } 1] \leq \delta < \frac{1}{4}$.
综上，$\mathbb{P}_0[A \cap B \cap C] \geq 1 - \frac{1}{4} - \frac{1}{4} - \frac{1}{4} = \frac{1}{4}$。

2. (**附加题**) 请证明，对于任意的 $\omega \in A \cap B \cap C$，有 $\frac{\mathbb{P}_1[\omega]}{\mathbb{P}_0[\omega]} \geq 4\delta$。
证明: $\mathbb{P}_0[\omega] = (\frac{1}{2})^T$,$\mathbb{P}_1[\omega] = (\frac{1}{2} + \varepsilon)^{K_T}(\frac{1}{2} - \varepsilon)^{T - K_T}$.
$\ln \frac{\mathbb{P}_1[\omega]}{\mathbb{P}_0[\omega]} = K_T \ln(\frac{1+2\varepsilon}{1-2\varepsilon}) + T \ln(1 - 2\varepsilon) \geq (\frac{1}{2}T - \sqrt{L \log \frac{1}{4\delta}}) \ln(\frac{1+2\varepsilon}{1-2\varepsilon}) + T \ln(1 - 2\varepsilon)$
$= \frac{1}{2}T \ln(1 - 4\varepsilon^2) - \sqrt{L \ln \frac{1}{4\delta}} \ln(\frac{1+2\varepsilon}{1-2\varepsilon}) \geq -2L \ln(1 - 4\varepsilon^2) - \sqrt{\frac{\ln^2 \frac{1}{4\delta}}{100\varepsilon^2}} \ln(\frac{1+2\varepsilon}{1-2\varepsilon})$
$\geq \frac{8\varepsilon^2}{100\varepsilon^2} \ln 4\delta + \ln(\frac{1+2\varepsilon}{1-2\varepsilon}) \frac{\ln 4\delta}{10\varepsilon} \geq (0.08 + 0.40866) \ln 4\delta \geq \ln(4\delta)$.
成立，where $\varepsilon \in (0, \frac{1}{8}), \ln 4\delta \leq -4, T \leq 4L$,并用到$\frac{1}{\varepsilon} \ln \frac{1+2\varepsilon}{1-2\varepsilon}$的单调性.

3. 请证明 $\mathbb{P}_1[C] > \delta$，并据此证明满足要求且保证 $\mathbf{E}_0[T] \leq L$ 的确定性算法是不存在的。
证明: $\mathbb{P}_1[C] \geq \mathbb{P}_1[A \cap B \cap C] \geq 4\delta \mathbb{P}_0[A \cap B \cap C] \geq 4\delta \cdot \frac{1}{4} = \delta$.
并且由2.可见等号是取不到的，即$\mathbb{P}_1[C] > \delta$，即该算法不能保证准确率，矛盾，则反证法假设不成立，即不存在这样的算法.

4. (**附加题**) 若 $\mathcal{A}$ 是一个随机算法，即 $\mathcal{A}$ 可以使用额外的随机数，那么 $\mathbf{E}_0[T] = \Omega\left(\frac{1}{\varepsilon^2} \log \frac{1}{\delta}\right)$ 的下界是否仍然成立？为什么？

5. (**附加题**) 如果你了解*相对熵（KL divergence）*，计算硬币每次独立抛掷中这两种伯努利分布的 KL 散度。你能否直观地解释，为了使两个分布产生的可观测序列在统计上变得“足够好区分”，我们需要积累与 $1/\varepsilon^2$ 成正比的信息量?