

[AI2613 第四次作业]

- 最近更新时间: 15:48, May 19, 2026
- 关于**AI使用**的说明：本次作业允许讨论和参考课外资料。如果在完成作业的过程中，与他人进行了讨论或参考了其他资料（包括使用AI工具），请在具体题目旁明确标注：和哪位同学探讨了思路，或参考了什么资料，或使用了哪种AI工具及其具体用途与使用程度。允许使用AI查询概念、LaTeX语法和检索公开资料；禁止使用AI直接生成答案、推导核心步骤或改写他人作业。
- 关于**附加题**的说明：作业中的附加题是选做的，会由助教进行批改，以供学习和反馈。但是这些题目的成绩不会纳入最终的作业总分，也不会提供额外的分数奖励。

问题一（DNA 演化）

在 DNA 序列的演化中，经常发生核苷酸的替换。假设我们只考虑四种核苷酸的情况，分别是 A, G, C, T ，其中 A 和 G 是嘌呤， C 和 T 是嘧啶。生物学家木村资生提出，由于嘌呤和嘧啶的结构差异，不同类型的核苷酸之间的替换概率是不同的，即 A, G 互换和 C, T 互换的概率显著高于嘌呤和嘧啶之间发生替换的概率。

我们可以用连续时间马尔可夫过程建模某个点位的核苷酸演化情况，令 $X(t) \in \{A, G, C, T\}$ 表示 t 时刻该点位的核苷酸种类，令 P_t 为其转移概率矩阵，假设其跳转速率为：

- 对于任意同类型但不相同的核苷酸 X, Y （即 X, Y 不相同但同为嘌呤或嘧啶），有 $q(X, Y) = \alpha$ ；
- 对于任意不同类型的核苷酸 X, Y （即 X, Y 中一个是嘌呤，另一个是嘧啶），有 $q(X, Y) = \beta$ 。

1. 我们先来考虑嘌呤和嘧啶的转换情况，令 B 和 D 分别表示嘌呤和嘧啶，令 $Y(t) \in \{B, D\}$ 表示时刻 t 该点位是嘌呤还是嘧啶，令 $\hat{P}_t$ 表示其转移概率矩阵，请计算 $\hat{P}_t(B, B)$ 和 $\hat{P}_t(B, D)$ 。

答：由题意对两链可以直接写出 $Q_X = \begin{pmatrix} -\alpha - 2\beta & \alpha & \beta & \beta \\ \alpha & -\alpha - 2\beta & \beta & \beta \\ \beta & \beta & -\alpha - 2\beta & \alpha \\ \beta & \beta & \alpha & -\alpha - 2\beta \end{pmatrix}$ ，

$$Q_Y = \begin{pmatrix} -2\beta & 2\beta \\ 2\beta & -2\beta \end{pmatrix},$$

$$\hat{P}_t = e^{tQ_Y} = e^{4\beta t I'} = I + (e^{4\beta t} - 1)I' = \begin{pmatrix} \frac{1}{2}(1 + e^{-4\beta t}) & \frac{1}{2}(1 - e^{-4\beta t}) \\ \frac{1}{2}(1 - e^{-4\beta t}) & \frac{1}{2}(1 + e^{-4\beta t}) \end{pmatrix}$$

其中 $I' = \begin{pmatrix} \frac{1}{2} & -\frac{1}{2} \\ -\frac{1}{2} & \frac{1}{2} \end{pmatrix}$ 满足 $(I')^n = I'$.

得 $\hat{P}_t(B, B) = \frac{1}{2}(1 + e^{-4\beta t})$, $\hat{P}_t(B, D) = \frac{1}{2}(1 - e^{-4\beta t})$.

2. 请计算 $P_t(A, A)$ 和 $P_t(A, C)$ 。

答：易得 Q_X 的特征值为 $0, -4\beta, -2\alpha - 2\beta$ (二重), 分别对应特征向量 $\frac{1}{2} \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \end{pmatrix}, \frac{1}{2} \begin{pmatrix} 1 \\ 1 \\ -1 \\ -1 \end{pmatrix},$

$\frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \\ 0 \\ 0 \end{pmatrix}, \frac{1}{\sqrt{2}} \begin{pmatrix} 0 \\ 0 \\ 1 \\ -1 \end{pmatrix}$. 且它们构成标准正交系, 于是

$Q_X = 0 \cdot P_1 + (-4\beta) \cdot P_2 + (-2\alpha - 2\beta) \cdot P_3 + (-2\alpha - 2\beta) \cdot P_4$, 其中 $P_i = v_i \cdot v_i^T$ 是对应的投影矩阵。因此, $P_t = e^{tQ_X} = \sum_{i=1}^4 e^{-\lambda_i t} P_i$, $P_t(A, A) = \frac{1}{4} + \frac{1}{4}e^{-4\beta t} + \frac{1}{2}e^{(-2\alpha-2\beta)t}$, $P_t(A, C) = \frac{1}{4} - \frac{1}{4}e^{-4\beta t}$.

这道题使用AI辅助复习了一下谱分解相关知识

问题二（倒霉蛋的一天）

倒霉蛋鲍勃最近非常不顺，他觉得整个世界都在针对他，请利用概率论和随机过程的知识，帮鲍勃分析他今天的遭遇。

1. **错过的公交车**: 鲍勃的车前几天坏了被送进了汽修厂，今天早晨，鲍勃去公交站坐车前往汽修厂取车。假设公交车的到达时间服从速率为 λ 的泊松过程。鲍勃在随机的一个时刻 t 到达车站（假设 t 足够大，可以认为这是一个从 $-\infty$ 时刻开始运行到现在的泊松过程）。

(1) 鲍勃觉得：“我每次一到车站，上一辆车肯定刚走没多久，而下一辆车又要等很久！”请计算鲍勃到达车站时，上一辆车离去的时间到下一辆车到来的时间的总间隔长度 L 的期望 $\mathbf{E}[L]$ 。

答：泊松分布具有无记忆性，上一辆车离去的时间 A 与下一辆车到来的时间 B 均服从参数为 λ 的指数分布，则 $\mathbf{E}[L] = \mathbf{E}[A + B] = \mathbf{E}[A] + \mathbf{E}[B] = 2/\lambda$ 。简单推导一下，固定 t ，用 $N(t)$ 表示到时刻 t 为止的事件个数： $A(t) = t - T_{N(t)}, \mathbb{P}[A(t) > a] = \mathbb{P}[\text{count}[t - a, t] = 0] = 1 - e^{-\lambda a}, A(t) \sim \exp(\lambda)$ 。 $B(t)$ 同理可证。

(2) 这个结果与平均发车间隔 $1/\lambda$ 矛盾吗？请直观地解释，为什么鲍勃会有这种倒霉的感受。

答：不矛盾，在 Bob 的平均感受中，间隔更长的区间具有更大的权重。

$$f_L(x) \propto x \cdot f(x) = x \cdot \lambda e^{-\lambda x}$$

2. **无尽等待的收费站**: 鲍勃在汽修厂取回了修好的车，开车回家。途径一个收费站，这里有并行的两条车道 A 和 B。鲍勃驶入了 A 道，而另一位司机史密斯驶入了 B 道，两人前面的等待车辆恰好一样多，鲍勃看着面前长长的队伍陷入了绝望，他觉得前面似乎有无限辆车在排队（本小题假设队伍是无限长

的)。假设 A 道和 B 道每次向前移动一辆车的时间分别服从参数为 μ 的指数分布, 且各次移动相互独立。

令 X_n 为系统发生第 n 次队伍移动时, 鲍勃相对于史密斯领先的车身数 ($X_0 = 0$, 如果落后, 则 X_n 为负)。请写出随机过程 $\{X_n\}_{n \geq 0}$ 的转移概率。

答: 作为生灭过程, 嵌入链转移概率 $\mathbb{P}[X_{n+1} = j | X_n = i] = \begin{cases} \frac{\mu}{\mu+\mu} = \frac{1}{2} & \text{for } j = i + 1, \\ \frac{1}{2} & \text{for } j = i - 1, \\ 0 & \text{otherwise.} \end{cases}$

3. **更慢的服务:** 鲍勃没有那么绝望了, 因为他发现前方队伍其实是有限的。经过漫长的等待, 他和史密斯终于都排到了队伍的最前面, 分别开始接受收费员的服务。假设两人的服务时间 X (鲍勃) 和 Y (史密斯) 是相互独立的指数分布随机变量, 参数均为 μ 。

鲍勃是个急性子, 如果他自己的服务时间 X 超过了史密斯服务时间 Y 的 3 倍 (即 $X/Y > 3$), 他就会向收费站投诉。

请计算服务时间比值的期望 $\mathbf{E}[X/Y]$, 并算出鲍勃投诉事件 $\{X > 3Y\}$ 发生的概率。

答: 直观上由对称性可知 $\mathbf{E}[X/Y] = 1$ 。然而实际上似乎并不是这样, 考虑累积分布概率:

$$\begin{aligned} \mathbb{P}[X/Y \leq k] &= \mathbb{P}[X \leq kY] = \int_y \mathbb{P}[X \leq ky] \cdot f_Y(y) dy = \int_0^\infty (1 - e^{-\mu ky}) \cdot \mu e^{-\mu y} dy \\ &= \int_0^\infty \mu e^{-\mu y} dy - \int_0^\infty \mu e^{-\mu y(1+k)} dy = 1 - \frac{\mu}{\mu(1+k)} = \frac{k}{1+k} \end{aligned}$$

$$\text{令 } Z = X/Y, f_Z(z) = \frac{d}{dz} P(Z \leq z) = \frac{d}{dz} \left(\frac{z}{1+z} \right) = \frac{1}{(1+z)^2}, z > 0,$$

$$\mathbf{E}[X/Y] = \mathbf{E}[Z] = \int_0^\infty z \cdot \frac{1}{(1+z)^2} dz \rightarrow \infty \text{ 调和发散。}$$

$$\mathbb{P}[X > 3Y] = \mathbb{P}[Z > 3] = 1 - \mathbb{P}[Z \leq 3] = 1 - \frac{3}{4} = \frac{1}{4}.$$

这道题使用AI辅助复习了一下概率统计相关知识。

4. **更倒霉的人:** 鲍勃回到家, 觉得自己今天真是倒霉透了! 他想看看是否有其他人比他更惨, 于是他来到了公交车站, 观察乘客们的等车时间, 假设乘客们的等待时间 $W_0, W_1, W_2, \dots$ 是独立同分布的连续随机变量。 W_0 即为鲍勃早上的等待时间, 他想要找到第一个等待时间比 W_0 还要长的人, 令随机变量 N 为第一个打破该倒霉记录的乘客序号, 即满足 $W_N > W_0$ 的最小正整数。

请计算随机变量 N 的概率质量函数 $\mathbb{P}[N = n]$, 并计算鲍勃为了等到这个比自己更倒霉的人, 所需要观察的期望人数 $\mathbf{E}[N]$ 。

答:

$$\begin{aligned} \mathbb{P}[N \geq n] &= \int_w \mathbb{P}[W_1 \leq w, W_2 \leq w, \dots, W_{n-1} \leq w] f_W(w) dw = \int_w F_W(w)^{n-1} f_W(w) dw \\ &= \frac{1}{n} F_W(w)^n \Big|_{w=0}^\infty = \frac{1}{n}, \mathbb{P}[N = n] = \mathbb{P}[N \geq n] - \mathbb{P}[N \geq n+1] = \frac{1}{n} - \frac{1}{n+1} = \frac{1}{n(n+1)} \end{aligned}$$

$$\mathbf{E}[N] = \sum_{n=1}^\infty n \cdot \mathbb{P}[N = n] = \sum_{n=1}^\infty \frac{1}{n+1} \rightarrow \infty.$$

这里有一个错误的证明, 它误以为 $W_i \leq W_0$ 事件是独立的。

$$\mathbb{P}[N \geq n] = \mathbb{P}[W_1 \leq W_0, W_2 \leq W_0, \dots, W_{n-1} \leq W_0] = \mathbb{P}[W_1 \leq W_0]^{n-1} = \left(\frac{1}{2}\right)^{n-1}$$

$$\mathbb{P}[N = n] = \mathbb{P}[N \geq n] - \mathbb{P}[N \geq n+1] = \left(\frac{1}{2}\right)^{n-1} - \left(\frac{1}{2}\right)^n = \left(\frac{1}{2}\right)^n$$

$$\mathbf{E}[N] = \sum_{n=1}^\infty n \cdot \mathbb{P}[N = n] = \sum_{n=1}^\infty n \cdot \left(\frac{1}{2}\right)^n = 2.$$

问题三（伪独立的近似）

假设外星人正在攻击地球，并要求你解决以下问题，否则将摧毁我们的家园：

“我将一枚均匀的硬币独立抛掷 $N = 20000$ 次。对于任意正整数 n ，令 p_n 表示这 20000 次抛掷中，最长连续出现正面的次数恰好为 n 的概率。请问 n 取何值时， p_n 达到最大？”

我们来运用所学的知识找出答案并拯救世界。

1. 精确计算每个 p_n 非常困难，但我们可以用泊松分布来近似计算。

定义指示变量 $X_i^{(n)}$ ：如果第 $i-1$ 次抛掷为反面（或者 $i=1$ ），且第 i 次到第 $i+n-1$ 次抛掷均为正面，则 $X_i^{(n)} = 1$ ；否则 $X_i^{(n)} = 0$ 。

令 $N = 20000$ 。可以认为 $\sum_{i=1}^N X_i^{(n)}$ 代表了长度至少为 n 的连续正面序列的出现次数。由于当 $|i-j| \geq n+1$ 时 $X_i^{(n)}$ 与 $X_j^{(n)}$ 独立，在 $n \ll N$ 时，我们可以近似地将 $\sum_{i=1}^N X_i^{(n)}$ 视为参数为 $\lambda_n = N \cdot 2^{-n-1}$ 的泊松随机变量 $Y^{(n)}$ 。

请基于此近似，推导出 p_n 的近似表达式，并通过对连续函数求导，求出使 p_n 最大化的 n 的近似实数值。

答：

$$p_n \approx \mathbb{P}[Y^{(n)} > 0, Y^{(n+1)} = 0] = \mathbb{P}[Y^{(n)} \geq 1] - \mathbb{P}[Y^{(n+1)} \geq 1] = -e^{-\lambda_n} + e^{-\lambda_{n+1}} \\ -e^{-\lambda_n} + e^{-\lambda_{n+1}} = -e^{-\lambda_n} + e^{-\frac{1}{2}\lambda_n} \text{ 对 } n \text{ 求导并令之为 } 0, e^{-\lambda_n} \cdot \lambda'_n - \frac{1}{2}e^{-\frac{1}{2}\lambda_n} \cdot \lambda'_n = 0$$

解得 $\lambda_n = 2 \ln 2$, $n = \log_2(N) - 1 - \log_2(2 \ln 2) \approx 12.816$ 。

2. 在第一小问的计算中，用泊松分布来近似 $\sum_{i=1}^N X_i^{(n)}$ 是不够严谨的，因为 $X_i^{(n)}$ 之间并非完全独立。我们现在使用陈-斯坦方法的一个推论来分析误差：

定理 (Chen-Stein Bound). 设 $X_1, \dots, X_N$ 为 N 个（不一定独立的）伯努利随机变量。记 $q_i = \mathbf{E}[X_i]$ 且 $\lambda = \sum_{i=1}^N q_i$ 。令 $Y \sim \text{Pois}(\lambda)$ 。假设对于每个 $i \in [N]$ ，存在一个邻域 $\mathcal{N}_i \subseteq [N] \setminus \{i\}$ ，使得 X_i 与集合 $\{X_j: j \notin \mathcal{N}_i \cup \{i\}\}$ 相互独立。则真实分布 μ （即 $\sum X_i$ ）与近似分布 π （即 Y ）之间的全变差距离满足：

$$d_{\text{TV}}(\mu, \pi) \leq \frac{1}{\lambda} \sum_{i=1}^N \left(q_i^2 + \sum_{j \in \mathcal{N}_i} (q_i q_j + \mathbf{E}[X_i X_j]) \right).$$

请据此计算出我们的问题中 $\sum_{i=1}^N X_i^{(n)}$ 和 $Y^{(n)}$ 的分布的全变差距离的上界。当 $n = \Theta(\log_2 N)$ 时，说明为何这个误差在 N 很大时可以忽略不计。

答： $q_i = \mathbf{E}[X_i] = \frac{1}{2^{n+1}}$ ，取 $N_i = \{j \in [N] : 0 < |i-j| \leq n\}$

$\mathbf{E}[X_i X_j] = \mathbb{P}[X_i = X_j = 1] = 0$ ，因为 $X_i^{(n)}$ 要求第 $i-1$ 次抛掷为反面。

$$\text{故 } d_{\text{TV}}(\mu, \pi) \leq \frac{1}{\lambda} \sum_{i=1}^N \left(q_i^2 + \sum_{j \in \mathcal{N}_i} (q_i q_j + \mathbf{E}[X_i X_j]) \right) \\ = \frac{1}{N \cdot 2^{-n-1}} \sum_{i=1}^N \left(\frac{1}{2^{2n+2}} + \sum_{j \in \mathcal{N}_i} \frac{1}{2^{2n+2}} \right) = \frac{1}{N \cdot 2^{-n-1}} \sum_{i=1}^N \left(\frac{2n+1}{2^{2n+2}} \right) = \frac{2n+1}{2^{n+1}}$$

3. **(附加题)** 请编写一段程序模拟这个抛硬币过程，统计出最长连续正面次数的经验众数，并观察它是否符合我们第一问求出的理论结果。